ENTREGA FINAL PROYECTO FINAL CAMILO BECERRA

La base de datos que estamos examinando ofrece una visión detallada de la población estudiantil en una institución educativa específica. Cada registro en la base de datos representa a un estudiante individual, con información que abarca tanto aspectos demográficos como académicos.

En el lado demográfico, los datos incluyen información como la edad, el género, el estrato socioeconómico y si el estudiante pertenece a alguna población vulnerable. Esto permite un análisis detallado de la composición de la población estudiantil y puede ayudar a identificar tendencias o patrones importantes.

En cuanto a los datos académicos, la base de datos proporciona detalles sobre el programa de estudios en el que está inscrito cada estudiante, la facultad a la que pertenece y el tipo de programa académico (ya sea una tecnología o un programa profesional). Estos datos pueden ser útiles para entender las tendencias en la elección de programas académicos y para identificar áreas de estudio populares.

Además, la base de datos también incluye información geográfica, como la ubicación del estudiante y el municipio de origen. Esta información puede ser útil para entender la distribución geográfica de los estudiantes y para identificar áreas con alta concentración de estudiantes.

En cuanto al análisis para las reglas de negocio tenemos las siguientes:

- 1. Unicidad del ID del estudiante: Cada estudiante se identifica por un ID único.
- 2. **Consistencia del periodo**: El periodo debe seguir el formato de un año seguido de ' 1' lo que indica el semestre.
- 3. **Formato del tipo de documento de identidad**: El tipo de documento de identidad debe ser 'CC', que representa la Cédula de Ciudadanía.
- 4. **Validación del código DANE**: El código DANE debe ser un número entero que corresponda a un municipio válido en Colombia.
- 5. **Correspondencia del municipio de origen**: El municipio de origen debe ser un nombre de municipio válido en Colombia.
- 6. **Verificación de la fecha de nacimiento**: La fecha de nacimiento debe ser una fecha válida y debe ser coherente con la edad del estudiante.

- 7. **Consistencia de la edad**: La edad del estudiante debe ser coherente con su fecha de nacimiento.
- 8. **Correspondencia del grupo etario**: El grupo etario debe ser consistente con la edad del estudiante.
- 9. **Formato de la vinculación**: La vinculación debe ser 'ANTIGUO' para los estudiantes que ya están matriculados.
- 10. Formato del género: El género debe ser 'M' (Masculino) o 'F' (Femenino).
- 11. **Rango del estrato**: El estrato debe ser un número entero entre 1 y 6.
- 12. **Validación del SNIES**: El SNIES debe ser un número entero que corresponda a un programa académico válido en Colombia.
- 13. **Correspondencia del plan de estudios**: El plan de estudios debe ser un nombre válido de plan de estudios.
- 14. **Correspondencia del programa académico**: El programa académico debe ser un nombre válido de programa académico.
- 15. **Correspondencia de la facultad**: La facultad debe ser un nombre válido de facultad.
- 16. Correspondencia del lugar: El lugar debe ser un nombre válido de lugar.
- 17. **Formato del tipo de programa**: El tipo de programa debe ser 'TECNOLOGÍA' o 'PROFESIONAL', dependiendo del plan de estudios.
- 18. **Formato de la longitud y la latitud**: La longitud y la latitud deben ser números flotantes que representen coordenadas geográficas válidas.
- 19. **Formato de la población vulnerable**: La población vulnerable debe ser una de las categorías predefinidas, como 'VICTIMA CONFLICTO', 'DESPLAZADO POR VIOLENCIA', 'EXCOMBATIENTE', 'NINGUNA', etc.

Ahora hablando de identificar y describir las entidades, atributos y relaciones que podemos presentar tenemos lo siguiente:

Entidades:

Persona: Esta entidad representa a un estudiante individual en la institución educativa.

Municipio: Esta entidad representa la ubicación geográfica de cada estudiante.

Programa: Esta entidad representa el programa académico en el que está inscrito cada estudiante.

Atributos:

Para la entidad Persona:

persona_id: Identificador único de la persona.

PERIODO: Periodo académico.

TIPO_DNI: Tipo de documento de identidad.

FECHA_NACIMIENTO: Fecha de nacimiento de la persona.

EDAD: Edad de la persona.

GRUPO_ETARIO: Grupo etario al que pertenece la persona.

VINCULACION: Tipo de vinculación de la persona con la institución.

GENERO: Género de la persona.

ESTRATO: Estrato socioeconómico de la persona.

SNIES: Código SNIES del programa académico en el que está inscrito la persona.

LUGAR: Lugar de residencia de la persona.

TIPO: Tipo de programa académico en el que está inscrito la persona.

LONGITUD: Longitud de la ubicación de la persona.

LATITUD: Latitud de la ubicación de la persona.

POB_VULNERABLE: Indica si la persona pertenece a alguna población vulnerable.

Para la entidad Municipio:

municipio_id: Identificador único del municipio.

COD_DANE: Código DANE del municipio.

MUNICIPIO_ORIGEN: Nombre del municipio de origen.

Para la entidad Programa:

programa_id: Identificador único del programa.

SNIES: Código SNIES del programa.

PLAN_ESTUDIOS: Plan de estudios del programa.

PROGRAMA_ACADEMICO: Nombre del programa académico.

FACULTAD: Facultad a la que pertenece el programa.

Relaciones:

Persona-Municipio: Una persona puede tener un municipio de origen. Esta relación se representa mediante la clave foránea persona_id_fk en la tabla Municipio.

Persona-Programa: Una persona puede estar inscrita en un programa. Esta relación se representa mediante la clave foránea persona_id_fk en la tabla Programa.

Diagrama Entidad Relación

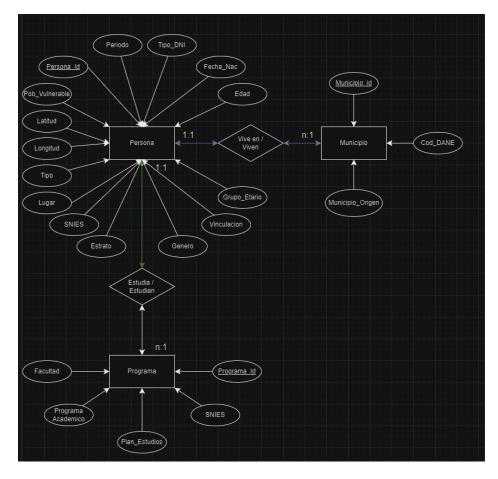
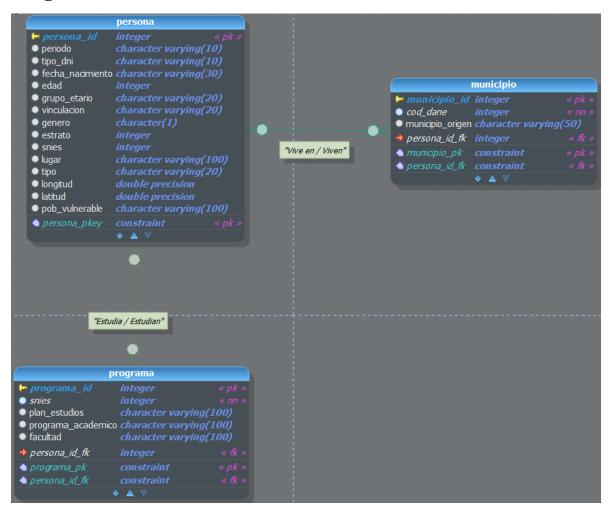


Diagrama Relacional



En ambos diagramas las relaciones de "Vive en / Viven" y "Estudia / Estudian", corresponden a hablar que asi como una persona solo puede vivir en un Municipio, un Municipio puede contener muchas personas que vivan en el según la Base de datos. Y que asi como una persona estudia solo un programa, en un mismo programa pueden estudiar varias personas según la Base de datos.

Link a la base de datos:

 $https://www.datos.gov.co/Educaci-n/Estudiantes-matriculados-del-Polit-cnico-Colombian/uun2-9uuk/about_data$

En cuanto al proceso de carga de información a la base de datos, lo que hice con estos nuevos datos fue:

Preparación de los Datos:

Primero, revisé los datos que iba a cargar. Realicé algunas correcciones menores, como eliminar caracteres especiales y asegurarme de que todos los datos estuvieran en el formato correcto CSV delimitado en este caso por ";". Finalmente, separe los datos por archivos diferentes según los iba a usar para cargarlos en PostgreSQL.

PERSONA_IE PERIODO	TIPO_DNI	FECHA_NACIEDAD	GRUPO_ETAI	VINCULACIO	GENERO	ESTRATO	SNIES	LUGAR	TIPO	LONGITUD	LATITUD	POB_VULN
1 2023_1	CC	10/29/1980 1	43 39 a 45 año:	ANTIGUO	M	2	108246	APARTADÓ	TECNOLOGÃ	-76633	7883	VICTIMA CO
2 2023_1	CC	***************************************	22 15 a 26 año:	ANTIGUO	M	2	3689	MEDELLÄN	PROFESIONA	-75567	6217	DESPLAZAD
3 2023_1	CC	01/27/2001 1	23 15 a 26 año:	ANTIGUO	M	2		MEDELLÂN	PROFESIONA	-75567	6217	NINGUNA
4 2023_1	CC	02/18/1988 1	35 27 a 38 año:	ANTIGUO	F	2		MEDELLÂN	PROFESIONA	-75567	6217	NINGUNA
5 2023_1	CC	03/19/1978 1	45 39 a 45 año:		M	2		MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
6 2023_1	CC	***************************************	20 15 a 26 año:	ANTIGUO	M	2		MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
7 2023_1	CC	03/31/1984 1	39 39 a 45 año:	ANTIGUO	M	2	3689	MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
8 2023_1	CC	***************************************	40 39 a 45 año:	ANTIGUO	M	2	3689	MEDELLÂN	PROFESIONA	-75567	6217	VICTIMA CO
9 2023_1	CC	03/27/1988 1	35 27 a 38 año:	ANTIGUO	F	3		MEDELLÂN	PROFESIONA	-75567	6217	NINGUNA
10 2023_1	CC	10/29/1982 1	41 39 a 45 año:	ANTIGUO	M	3	108727	MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
11 2023_1	CC	07/21/1983 1	40 39 a 45 año:	ANTIGUO	M	2		MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
12 2023_1	CC	07/14/1980 1	43 39 a 45 año:	ANTIGUO	M	2	2937	MEDELLÄN	PROFESIONA	-75567	6217	EXCOMBAT
13 2023_1	CC	09/20/1986 1	37 27 a 38 año:	ANTIGUO	M	2	2937	MEDELLÂN	PROFESIONA	-75567	6217	NINGUNA
14 2023_1	CC	***************************************	42 39 a 45 año:	ANTIGUO	F	2	2540	MEDELLÂN	PROFESIONA	-75567	6217	NINGUNA
15 2023_1	CC	05/29/1981 1	42 39 a 45 año:	ANTIGUO	F	2	2540	MEDELLÃN	PROFESIONA	-75567	6217	NINGUNA
16 2023_1	CC	09/20/1979 1	44 39 a 45 año:	ANTIGUO	M	2			TECNOLOGÃ	-75567	6217	VICTIMA CO
17 2023_1	CC	03/22/1982 1	41 39 a 45 año:	ANTIGUO	F	3		MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
18 2023_1	CC	10/20/1986 1	37 27 a 38 año:	ANTIGUO	F	2			TECNOLOGÃ	-75567	6217	NINGUNA
19 2023_1	CC	***************************************	38 27 a 38 año:	ANTIGUO	F	3			PROFESIONA	-75567	6217	NINGUNA
20 2023_1	CC	12/14/1978 1	45 39 a 45 año:	ANTIGUO	M	3	108270	MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
21 2023_1	CC	07/18/1984 1	39 39 a 45 año:	ANTIGUO	M	3		MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA
22 2023_1	CC	09/16/1988 1	35 27 a 38 año:	ANTIGUO	F	2		MEDELLÄN	PROFESIONA		6217	NINGUNA
23 2023_1	CC	***************************************	43 39 a 45 año:	ANTIGUO	F	2			PROFESIONA	-76633	7883	NINGUNA
24 2023_1	CC	06/14/1984 1	39 39 a 45 año:	ANTIGUO	M	3			TECNOLOGÃ	-75567	6217	NINGUNA
25 2023_1	CC	***************************************	39 39 a 45 año:	ANTIGUO	M	3	2937	MEDELLÄN	PROFESIONA	-75567	6217	NINGUNA

PROGRAMA.	SNIES	PLAN_ESTUD	PROGRAMA_	FACULTAD	PERSONA_ID	_FK
1	108246	6910	TECNOLOGÃ	FACULTAD D	1	
2	3689	9511	INGENIERÃA	FACULTAD D	2	
3	108727	7510	LICENCIATUR	FACULTAD D	3	
4	2540	9011	CONTADURÃ	FACULTAD D	4	
5	2937	9209	INGENIERÃA	FACULTAD D	5	
6	2540	9011	CONTADURÃ	FACULTAD D	6	
7	3689	9511	INGENIERÃA	FACULTAD D	7	
8	3689	9511	INGENIERÃA	FACULTAD D	8	
9	3347	8310	INGENIERÃA	FACULTAD D	9	
10	108727	7510	LICENCIATUR	FACULTAD D	10	
11	108727	7510	LICENCIATUR	FACULTAD D	11	
12	2937	9209	INGENIERÃA	FACULTAD D	12	
13	2937	9209	INGENIERÃA	FACULTAD D	13	
14	2540		CONTADURÃ			
15	2540	9010	CONTADURÃ	FACULTAD D	15	
16	2859	210	TECNOLOGÃ	FACULTAD D	16	
17	3347	8310	INGENIERÃA	FACULTAD D	17	
18	1749	309	TECNOLOGÃ	FACULTAD D	18	
19	2937	9209	INGENIERÃA	FACULTAD D	19	
20	108270	8710	INGENIERÃA	FACULTAD D	20	
21	2937	9209	INGENIERÃA	FACULTAD D	21	
22	2937		INGENIERÃA		22	
23	107648	8210	INGENIERÃA	FACULTAD D	23	
24	110950		TECNOLOGÃ			
25	2937	9209	INGENIERÃA	FACULTAD D	25	
26	55167		COMUNICAC		26	
27	2714		TECNOLOGÃ			
28	3348		INGENIERÃA			
29	2937	9209	INGENIERÃA	FACULTAD D	29	

MUNICIPIO_	COD_DANE	MUNICIPIO_	PERSONA_ID_FK
1	5147	CAREPA	1
2	5088	BELLO	2
3	5125	CAICEDO	3
4	5001	MEDELLIN	4
5	5001	MEDELLIN	5
6	5079	BARBOSA	6
7	5001	MEDELLIN	7
8	5665	SAN PEDRO I	8
9	5001	MEDELLIN	9
10	5266	ENVIGADO	10
11	5360	ITAGUI	11
12	5380	LA ESTRELLA	12
13	5001	MEDELLIN	13
14	5001	MEDELLIN	14
15	27075	BAHIA SOLAI	15
16	5001	MEDELLIN	16
17	5001	MEDELLIN	17
18	5360	ITAGUI	18
19	5001	MEDELLIN	19
20	5380	LA ESTRELLA	20
21	5001	DESCONOCIO	21
22	5001	MEDELLIN	22
23	5147	CAREPA	23
24	5001	MEDELLIN	24
25	5088	BELLO	25
26	5266	ENVIGADO	26
27	5001	MEDELLIN	27
28	5001	MEDELLIN	28
29	5001	MEDELLIN	29

Creación de la Tabla:

Después de preparar los datos, creé tablas en la base de datos para almacenarlos. Definí cada columna de la tabla para que coincidiera con los tipos de datos y la estructura de los datos a cargar.

```
CREATE TABLE Persona (

persona_id integer,

PERIODO VARCHAR(10),

TIPO_DNI VARCHAR(10),

FECHA_NACIMIENTO VARCHAR(30),

EDAD INTEGER,
```

```
GRUPO_ETARIO VARCHAR(20),
  VINCULACION VARCHAR(20),
  GENERO CHAR(1),
  ESTRATO INTEGER,
  SNIES INTEGER,
 LUGAR VARCHAR(100),
 TIPO VARCHAR(20),
 LONGITUD FLOAT,
  LATITUD FLOAT,
  POB_VULNERABLE VARCHAR(100),
       PRIMARY KEY (persona_id)
);
CREATE TABLE Municipio (
  municipio_id INTEGER,
  COD_DANE INTEGER NOT NULL,
  MUNICIPIO_ORIGEN VARCHAR(50),
       persona_id_fk INTEGER,
       CONSTRAINT municipio_pk PRIMARY KEY (municipio_id),
  CONSTRAINT persona_id_fk FOREIGN KEY(persona_id_fk) REFERENCES Persona(persona_id)
);
CREATE TABLE Programa (
  programa_id INTEGER,
  SNIES INTEGER NOT NULL,
  PLAN_ESTUDIOS VARCHAR(100),
  PROGRAMA_ACADEMICO VARCHAR(100),
  FACULTAD VARCHAR(100),
       persona_id_fk INTEGER,
       CONSTRAINT programa_pk PRIMARY KEY (programa_id),
  CONSTRAINT persona_id_fk FOREIGN KEY(persona_id_fk) REFERENCES Persona(persona_id)
);
```

Carga de Datos:

Una vez que la tabla estuvo lista, procedí a cargar los datos. Utilicé una herramienta de administración de bases de datos para cargar el archivo CSV que contenía los datos. Solamente tuve que especificar la ubicación del archivo y la tabla de destino.

```
-- Cargar datos en la tabla "Persona"

COPY Persona (PERSONA_ID, PERIODO, TIPO_DNI, FECHA_NACIMIENTO, EDAD, GRUPO_ETARIO, VINCULACION, GENERO, ESTRATO
FROM 'D:\Descargas\Estudiantes_Persona.csv' DELIMITER ';' CSV HEADER;

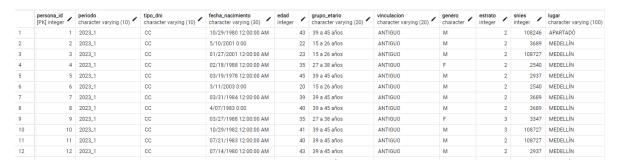
COPY Municipio (MUNICIPIO_ID, COD_DANE, MUNICIPIO_ORIGEN, PERSONA_ID_FK)
FROM 'D:\Descargas\Estudiantes_Municipio.csv' DELIMITER ';' CSV HEADER;

-- Cargar datos en la tabla "Programa"
COPY Programa (PROGRAMA_ID, SNIES, PLAN_ESTUDIOS, PROGRAMA_ACADEMICO, FACULTAD, PERSONA_ID_FK)
FROM 'D:\Descargas\Estudiantes_Programa.csv' DELIMITER ';' CSV HEADER;
```

Validación de Datos:

Después de la carga, verifiqué que los datos se hubieran cargado correctamente. Ejecuté algunas consultas simples para asegurarme de que todos los datos estuvieran en su lugar y que no hubiera errores obvios.

select * from Persona



select * from Municipio

	municipio_id [PK] integer	cod_dane integer	municipio_origen character varying (50)	persona_id_fk integer
1	1	5147	CAREPA	1
2	2	5088	BELLO	2
3	3	5125	CAICEDO	3
4	4	5001	MEDELLIN	4
5	5	5001	MEDELLIN	5
6	6	5079	BARBOSA	6
7	7	5001	MEDELLIN	7
8	8	5665	SAN PEDRO DE URABA	8
9	9	5001	MEDELLIN	9
10	10	5266	ENVIGADO	10
11	11	5360	ITAGUI	11
12	12	5380	LA ESTRELLA	12
13	13	5001	MEDELLIN	13
14	14	5001	MEDELLIN	14

select * from Programa

	programa_id / [PK] integer	snies integer	plan_estudios character varying (100)	programa_academico character varying (100)	facultad character varying (100)	persona_i integer
1	1	108246	6910	TECNOLOGÍA EN DESARROLLO DE SOFTWARE	FACULTAD DE INGENIERÍA	
2	2	3689	9511	INGENIERÍA CIVIL	FACULTAD DE INGENIERÍA	
3	3	108727	7510	LICENCIATURA EN EDUCACIÓN FÍSICA, RECREACIÓN Y DEPORTE	FACULTAD DE EDUCACIÓN FÍSICA, RECREACIÓN Y DEPORTE	
4	4	2540	9011	CONTADURÍA PÚBLICA	FACULTAD DE ADMINISTRACIÓN	
5	5	2937	9209	INGENIERÍA DE PRODUCTIVIDAD Y CALIDAD	FACULTAD DE ADMINISTRACIÓN	
6	6	2540	9011	CONTADURÍA PÚBLICA	FACULTAD DE ADMINISTRACIÓN	
7	7	3689	9511	INGENIERÍA CIVIL	FACULTAD DE INGENIERÍA	
8	8	3689	9511	INGENIERÍA CIVIL	FACULTAD DE INGENIERÍA	
9	9	3347	8310	INGENIERÍA EN HIGIENE Y SEGURIDAD OCUPACIONAL	FACULTAD DE INGENIERÍA	
10	10	108727	7510	LICENCIATURA EN EDUCACIÓN FÍSICA, RECREACIÓN Y DEPORTE	FACULTAD DE EDUCACIÓN FÍSICA, RECREACIÓN Y DEPORTE	
11	11	108727	7510	LICENCIATURA EN EDUCACIÓN FÍSICA, RECREACIÓN Y DEPORTE	FACULTAD DE EDUCACIÓN FÍSICA, RECREACIÓN Y DEPORTE	
12	12	2937	9209	INGENIERÍA DE PRODUCTIVIDAD Y CALIDAD	FACULTAD DE ADMINISTRACIÓN	
13	13	2937	9209	INGENIERÍA DE PRODUCTIVIDAD Y CALIDAD	FACULTAD DE ADMINISTRACIÓN	
				✓ Suc	cessfully run. Total query runtime: 71 msec. 3008 rows affect	cted. X

Análisis identificados

Segmentación demográfica y sociodemográfica: Se sugiere agrupar a los estudiantes según variables como edad, género, estrato socioeconómico y lugar de origen. Esta segmentación permitiría comprender mejor la composición de nuestros estudiantes y adaptar nuestros programas según sus necesidades específicas.

Evaluación de la vulnerabilidad y necesidades especiales: Se propone examinar cómo la condición de "población vulnerable" está repartida entre los estudiantes. Este enfoque permitiría identificar grupos específicos que podrían requerir apoyo adicional o intervenciones específicas.

Análisis de las ciudades donde están los estudiantes: Se propone investigar en qué ciudades estudian los estudiantes. Este análisis permitiría identificar factores locales que influyen en su experiencia educativa y diseñar estrategias de apoyo adaptadas a sus necesidades específicas.

Sesion de discusión de los análisis Segmentación Demográfica y Sociodemográfica

Ventajas:
Personalización de programas educativos.
Mejor comprensión de la composición estudiantil.
Estrategias efectivas de retención y éxito.
Desventajas:
Complejidad administrativa.
Posible estigmatización de los estudiantes.
Evaluación de la Vulnerabilidad y Necesidades Especiales
Ventajas:
Identificación de estudiantes que requieren apoyo adicional.
Focalización de recursos para mayor equidad.
Mejora del bienestar estudiantil.

Dependencia de datos precisos.

Riesgo de exclusión de algunos estudiantes vulnerables.

Análisis de las Ciudades donde están los Estudiantes

Ventajas:

Desventajas:

Comprensión del contexto local.

Diseño de estrategias de apoyo específicas.

Optimización de recursos.

Desventajas:

Variabilidad geográfica.

Costos de investigación.

Conclusiones

Selección de la Fuente de Datos:

La selección de la fuente de datos fue una de las primeras decisiones que tomaron tiempo. Al final me decidí por una que parecía interesante por su enfoque detallado en los estudiantes, también esto fue luego de haber tenido que cambiarla para usarla en lugar de la primera fuente de datos que encontré que se quedaba corta en contenido para la idea general del proyecto.

Desarrollo y Carga de la Base de Datos:

El desarrollo y la carga de la base de datos fueron más laboriosos. Inicialmente tuve que cambiar de fuente de datos debido a problemas con la calidad y la consistencia de los datos. Este cambio requirió ajustes significativos, pero finalmente logre consolidar una base de datos más confiable.

Desarrollo en Dash:

El desarrollo de la visualización de datos en Dash también fue interesante. Tuve varias complicaciones técnicas como errores en los puertos a los que debia conectarme para que funcionara y requería correcciones constantes. A pesar de estos errores, logre implementar las funcionalidades necesarias y mejorar la interfaz para que fuera intuitiva y útil.

Conclusión:

A lo largo del proyecto fue bastante interesante y entretenido aprender a usar todas las herramientas, desde la selección de la fuente de datos hasta la implementación técnica en Dash. Estas experiencias me han dado un valioso aprendizaje y una base solida para las aplicaciones de todos estos conocimientos.

https://github.com/CamiloBecerra1606/Proyecto-Ingenieria-Datos-Camilo-Becerra